

Article

시계열 기계학습을 이용한 한반도 남해 해수면 온도 예측 및 고수온 탐지

정시훈 ¹⁾ · 김영준 ²⁾ · 박수민 ¹⁾ · 임정호 ^{3)†}

Prediction of Sea Surface Temperature and Detection of Ocean Heat Wave in the South Sea of Korea Using Time-series Deep-learning Approaches

Sihun Jung ¹⁾ · Young Jun Kim ²⁾ · Sumin Park ¹⁾ · Jungho Im ^{3)†}

Abstract: Sea Surface Temperature (SST) is an important environmental indicator that affects climate coupling systems around the world. In particular, coastal regions suffer from abnormal SST resulting in huge socio-economic damage. This study used Long Short Term Memory (LSTM) and Convolutional Long Short Term Memory (ConvLSTM) to predict SST up to 7 days in the south sea region in South Korea. The results showed that the ConvLSTM model outperformed the LSTM model, resulting in a root mean square error (RMSE) of 0.33°C and a mean difference of -0.0098°C. Seasonal comparison also showed the superiority of ConvLSTM to LSTM for all seasons. However, in summer, the prediction accuracy for both models with all lead times dramatically decreased, resulting in RMSEs of 0.48°C and 0.27°C for LSTM and ConvLSTM, respectively. This study also examined the prediction of abnormally high SST based on three ocean heatwave categories (i.e., warning, caution, and attention) with the lead time from one to seven days for an ocean heatwave case in summer 2017. ConvLSTM was able to successfully predict ocean heatwave five days in advance.

Key Words: sea surface temperature, prediction, ocean heatwave, Korea peninsula, machine learning, time-series

요약: 해수면 온도는 전 세계 해양, 기상 현상에 영향을 주고 해양 환경 변화와 생물에게 영향을 주는 중요한 요소이다. 특히, 우리나라 남해안을 비롯한 연안 지역의 경우 어업 및 양식업 등의 수산업이 많이 발달하여, 매년 고수온 현상으로 인한 사회·경제적 피해가 발생하고 있다. 따라서 위성 자료와 같은 광범위한 지역을 감시

Received October 1, 2020; Revised October 15, 2020; Accepted October 19, 2020; Published online October 26, 2020

¹⁾ 울산과학기술원 도시환경공학과 석박사 통합과정생 (Combined Ms/PhD student, Department of Urban and Environmental Engineering, Ulsan National Institute of Science and Technology)

²⁾ 울산과학기술원 도시환경공학과 박사과정생 (PhD Student, Department of Urban and Environmental Engineering, Ulsan National Institute of Science and Technology)

³⁾ 울산과학기술원 도시환경공학과 교수 (Professor, Department of Urban and Environmental Engineering, Ulsan National Institute of Science)

† Corresponding Author: Jungho Im (ersgis@unist.ac.kr)

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/3.0>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

할 수 있는 자료를 활용한 해수면 온도 및 공간적 분포의 예측기술 개발을 통하여 피해를 예방할 수 있는 시스템을 구축할 필요가 있다. 해수면 온도 예측은 기존의 수치 모델을 통해서 예측을 진행하였지만, 다수의 역학적 요인들을 사용하여 예측 결과 산출 시 복잡함이 존재한다. 최근 기계학습 및 딥러닝 기법이 발달함에 따라 해양 분야의 예측에 적용하는 연구가 진행되고 있다. 본 연구는 그 중 시·공간적인 일관성 및 정확도가 높은 장단기 기억(Long Short Term Memory, LSTM)과 합성곱 장단기 기억(Convolutional Long Short Term Memory, ConvLSTM) 딥러닝 기법을 사용하여 남해지역의 해수면온도 예측 및 2017년부터 2019년까지의 고수온 발생 건에 대해서 예측 결과의 공간 분포와 공간 분포와 예측 가능성에 대해 분석을 하였다. 1일 예측 모델의 정확도는 RMSE 기준으로 ConvLSTM(전체: 0.33°C, 봄: 0.34°C, 여름: 0.27°C, 가을: 0.32°C, 겨울: 0.36°C)이 LSTM 기반의 예측 모델(전체: 0.40°C, 봄: 0.40°C, 여름: 0.48°C, 가을: 0.39°C, 겨울: 0.34°C)보다 우수한 성능을 보였다. 2017년 고수온 발생 사례에 대해서 해수면 온도 예측과 고수온 탐지 성능에서 ConvLSTM은 5일까지 경보를 탐지하지만, LSTM의 경우 2일 예측 이후 해수면 온도를 과소 추정하는 경향이 커짐에 따라 탐지하지 못하였다. 시·공간적인 해수면 온도 예측 시 ConvLSTM이 LSTM에 비해 적절한 모델로 판단된다.

1. 서론

해수면 온도(sea surface temperature, SST)는 전세계 해양의 열 분배, 해양-대기 순환 현상을 결정하는 가장 중요한 변수이다. 해양의 상층부에서 장, 단기적인 해양순환을 일으키며 물리적인 영향 및 생지화학 변화에 대한 영향을 끼친다(Donlon *et al.*, 2012). 해수면 온도 변화는 전세계적인 기후 변화와 해양 시스템 간의 상호작용으로 인해 발생한다. 특히 북서태평양 해역은 태평양으로부터 고위도로 북상하는 쿠로시오 난류의 영향을 크게 받으며 엘니뇨, 라니냐 등의 장기간 다양한 규모의 해양현상이 난류의 강도 및 흐름을 변화시킨다(Nan *et al.*, 2015). 또한, 한반도 해역에서의 대기 폭염 현상, 양자강 저염수의 황해로의 대량 유입, 대기의 고기압 전선 분포 등의 다양한 외력 요인이 한반도 해수면 온도 분포와 열류량에 영향을 미치며 대한민국 해역에 고수온 현상을 자주 발생시키고 있다(KIEST., 2018). 이러한 고수온 현상은 다양한 사회환경적인 문제를 야기하기 때문에 해수면 온도를 예측하는 연구가 최근 활발히 수행되어 왔다.

해수면 온도 예측 방법은 크게 수치 모델을 이용하는 경우와 자료 중심적(Data-driven)인 모델을 사용하는 것으로 나눌 수 있다. 해양 수치 모델인 경우에는 국내외 다양한 기관에서 3차원 자유 지형(free surface), 지형 추적(terrain following), 원시 방정식(primitive equations) 열역학(thermo dynamics)을 활용한 해양 모델인 Regional Ocean Modeling System (ROMS), Nucleus for European

Modelling of the Ocean (NEMO)와 같은 해양 모델을 사용하여 일사량, 해류 등 다수의 파라미터를 입력자료로 사용하고 실시간 자료동화를 통해서 해수면 온도의 유동과 변위를 예측하고 있다. 미국 National Ocean Partnership Program (NOPP)에서는 3차원 해양 수치 모델인 HYbrid Coordinate Ocean Model (HYCOM)을 이용해 7일 예측 자료를 제공하고 있으며(<https://www.hycom.org>), 유럽 Copernicus Marine Service에서는 NEMO 해양 모델을 사용하여 10일 예측 자료를 제공하고 있다(<https://marine.copernicus.eu/>). 국내의 경우, 한국해양과학기술원(Korea Institute of Ocean Science Technology, KIOST)에서 전구 범위 지역은 해양순환모델(MOM5)에 HYCOM 해양 수치 모델 자료, The Array for Real-time Geostrophic Oceanography (ARGO), World Ocean Data base로부터 수집되는 다양한 현장 자료와 Optimal interpolated sea surface temperature (OISST) 등을 입력자료로 Ensemble Optimal Interpolation (EnOI) 자료동화방법을 통하여 산출한다. 또한, 황동중국해지역에 대해서는 지역적 해양모델인 ROMS 모델을 사용하여 운용해양 시스템인 KOOS (Korea Operational Oceanographic System)를 구축하였고 3일 예측 자료를 산출한다(KIEST, 2013).

수치 모델 접근법과 달리 통계 및 기계학습 기법을 적용한 자료 중심적(Data-driven) 방법론도 다양하게 연구되어 왔다. Xue and Leetmaa.(2000)은 다변수 경험직교 함수로 이루어진 통계학적 모델인 Markov model을 사용하여 동태평양 해수면 온도를 9개월까지 예측

하여 0.5의 상관성을 보였고 북서태평양 지역에 대해서 3개월까지 예측하여 0.4 이상의 상관성을 보였다. Lins *et al.*(2013)은 서포트 벡터 머신(Support vector machine, SVM)을 활용하여 대서양의 두 mooring buoy의 장기간 시계열 자료(7년 이상)를 사용하여 1년까지 예측하는 모델을 구축하였다. 기존의 SVM과 전통적인 회귀방법은 장기간의 시계열특성을 모의하는데에 상대적으로 낮은 성능을 보였다. 반면, 시계열 자료를 모의하는데 특화된 LSTM을 사용한 선행 연구들에서 기존의 통계적 방법과 비교해서 상대적으로 우수한 성능을 보였다 (Zhang *et al.*, 2017). 또한 합성곱 신경망(Convolutional neural network)을 LSTM과 단순 결합한 모델인 Fully connected LSTM (FC-LSTM)이 해수면 온도 예측 연구에서 SVM보다 상대적으로 우수한 해수면 온도 예측 성능을 보여주었다(Yang *et al.*, 2018). 특히 Xiao *et al.*(2019b)는 시공간적인 학습을 동시에 하기위해 3차원 벡터 형태의 입력자료와 행렬 연산시 활용되는 단순 행렬곱을 합성곱으로 바꾼 Convolutional LSTM (ConvLSTM)을 적용하였다. OISST (해상도 1/4°)를 사용하였으며 1일부터 10일까지의 해수면 온도 예측을 수행하여 10일 예측 시 SVM과 LSTM의 RMSE는 1°C 이상 이였으며 ConvLSTM의 경우는 약 0.9°C로 ConvLSTM이 상대적으로 높은 성능을 보였다.

한반도 남해 연안은 연안 어로, 양식업 등 수산업이 활발하게 이루어지는 해역이다. 하지만 특정 기간동안 이상 고수온 현상이 발생하여 생태학적 변화를 일으켜 광범위한 피해를 끼친다(Lee *et al.*, 2018). 기상청 이상기후 보고서에 따르면 2018년 7월 24일부터 9월 4일까지 43일간 고수온 특보가 발령되었으며, 총 604억 원 이상의 양식업 피해가 발생하였다(KMA, 2019). 국립수산과학원에서는 전국 연안 및 주요 양식어장에 대한 지속적인 해황에 대한 모니터링을 하며 양식장 등의 설치된 관측 센서와 실시간 다수의 기관의 부이 온도자료를 통해 빈산소수괴, 냉수대, 고수온 속보등 이상 현상에 대한 실시간 속보를 제공해주고 있다(<http://www.nifs.go.kr/femo>). 국립수산과학원이 정한 우리나라에서의 이상 고수온의 정의는 절대적인 수치로 28°C를 기준으로 정의한다. 해수면 온도 예측 시 수온 28°C에 도달이 예상되는 해역에는 고수온 주의보가 발령되며, 28°C 이상의 수온이 3일 이상 지속되는 해역에는 고수온 경보가 발

령 된다. 또한 평년(최근 10년간) 대비 2°C와 3°C 이상 수온이 상승할 경우 각각 고수온 주의보와 경보를 발령 한다 (KMA, 2019). 기존 국립수산과학원의 고수온 속보는 연안의 현장 관측 센서의 관측 값에 따라 속보를 발령하기에 외양역의 고수온 해류의 분포 및 발생에 대한 모니터링을 할 수 없는 한계를 가지고 있다. 국지적인 모니터링을 극복하기 위해 위성 원격탐사를 활용하면 이상 해수면 온도에 대한 광범위한 시공간적인 탐지 및 분석이 가능하다(Moon and Yang, 2009; Kim and Yang, 2019). Kim *et al.*(2019)의 연구에서는 다수의 인공위성으로 산출한 합성 해수면 온도자료와 유럽 기상청 (Meteorological Office; Met Office)의 Operational Sea Surface Temperature and Sea Ice Analysis (OSTIA) 해수면 온도 합성 자료를 통해 이상치(anomaly)를 산출하여 탐지에 활용하였다. 고수온 발생 해역에 대한 탐지·비교를 수행하였으며 그 중 남해 연안에서의 현장 관측자료와 비교하여 위성기반 탐지 결과가 유사함을 보였다. 기존의 위성 자료를 통한 이상 수온 탐지 연구는 준 실시간으로 위성 정보가 수신되어야 탐지 분석이 가능하며 예측할 수 없는 한계가 있다. 최근 딥러닝 기법을 활용한 해수면 온도 예측 연구들은 유의미한 결과를 도출하였으며 이상 고수온 탐지에 활용할 수 있을 것으로 보인다.

본 연구에서는 기존 해수면 온도 예측 연구에서 우수한 성능을 보여준 LSTM과 ConvLSTM 딥러닝 기법을 이용하여 우리나라 남해 해역의 해수면 온도를 중단기 (1-7일 예측) 예측하고 고수온 예측 사례를 분석하였다. 연구지역에 대한 해수면 온도 예측 모델의 시공간적인 정확도 및 오류와 고수온 발생 예측 및 탐지를 국립수산과학원의 고수온 속보와 공간 분포와 예측 가능성을 분석하였다.

2. 연구지역 및 연구자료

1) 연구지역

한반도의 남해지역과 일본 사이의 해역으로 범위는 위도 34.475°E ~ 33.025°N, 경도 126.972°E ~ 128.925°E 으로 설정하였다. 우리나라 남해는 얕은 수심과 복잡한 연안구조를 가지고 있으며 쿠로시오 난류로부터 분화

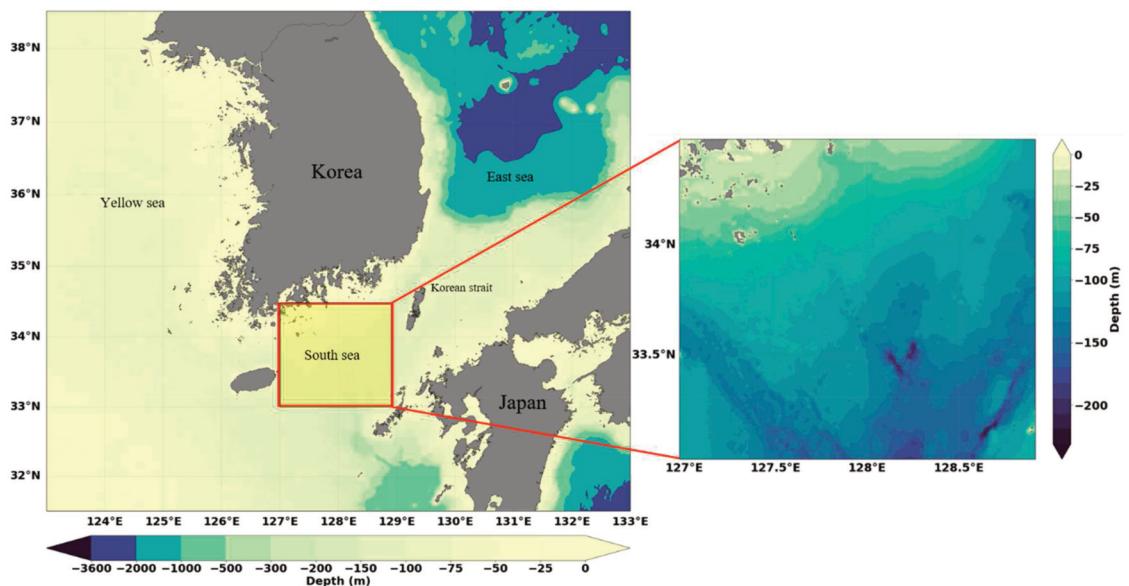


Fig. 1. The study area in the yellow box area is study area in this study. The bathymetry map provided by The General Bathymetric Chart of the Oceans (<https://www.gebco.net>) is used as a background image.

되는 고온·고염의 대마난류가 대한 해협을 통하여 동해로 흐르는 해수의 열염 순환 및 해양환경 변화 등 물리적·생물학적인 영향을 크게 미치는 지역이다(Seong *et al.*, 2010). 이상 고수온 현상이 발생하며 넓은 범위에 걸쳐 양식장 생물 폐사 및 해양생태계에 피해를 발생시킨다(Kim and Yang, 2019).

2) 해수면 온도 합성 자료

인공위성 기반 해수면 온도는 열적외, 마이크로파 기반의 위성 자료를 이용하여 산출한다. 열적외 센서와 마이크로파 센서 기반의 위성에서는 대기와 해양 현상 그리고 육지로 인한 신호의 소실 및 오염으로 인한 대량의 자료 소실이 발생한다. 자료부재의 문제를 해결하기 위해서 여러 기관에서 극궤도, 정지궤도, 실시간 현장자료 그리고 기후장 등 다양한 시공간적 해수면 온도 자료를 자료동화 방식을 통해 빈공간이 없는 해수면 온도 자료를 산출한다(Reynold *et al.*, 2007; Donlon *et al.*, 2014; Chin *et al.*, 2017). Woo and Park(2020)은 한반도 연안의 실시간 현장 관측 부이 자료를 사용해서 7가지의 해수면 온도 합성 자료의 비교·검증하였다. 그 중 연안 부이와 시계열적인 일관성이 상대적으로 높았던 유럽 기상청의 OSTIA 자료를 이번 연구의 입력 자료로 사용하였다. OSTIA 해수면 합성 온도 자료의 공간해상도는 0.05°, 시

간해상도는 1일이며 실시간 해수면온도 자료와 현장자료를 최적 보간(Optimal interpolation)으로 동기화 하여 빈공간이 없는 자료를 산출하며 정확도는 0.57K의 Root Mean Square Error (RMSE)를 가진다(Donlon *et al.*, 2012). OSTIA 자료는 Copernicus Marine Environment Monitoring Service (CMEMS; <http://marine.copernicus.eu>)에서 제공하며 본 연구에서는 2007년 1월 1일부터 2019년 12월 31일 까지의 총 13년의 일일 해수면온도 합성 자료를 사용하였다.

3. 연구방법

1) 연구방법

본 연구에서는 최근 시계열 예측 분야에서 많은 활용을 보여주고 있는 딥러닝 기법인 LSTM과 ConvLSTM 을 이용하여 일일 해수면 온도를 1-7일 예측하는 모델과 2017년 8월 17일의 고수온 사례를 7일 전부터 1일 전 까지 예측 모델을 구축하였다. 예측 모델의 학습 기간은 2006년부터 2016년까지 10년 자료를 학습하고 2017년부터 2019년까지 3년간의 자료로 모델 검증을 진행하였다. 연구지역 내 OSTIA 해수면 온도 자료에서 거문도 지역의 3개 픽셀이 육지 마스킹에 의해 값이 존재하지

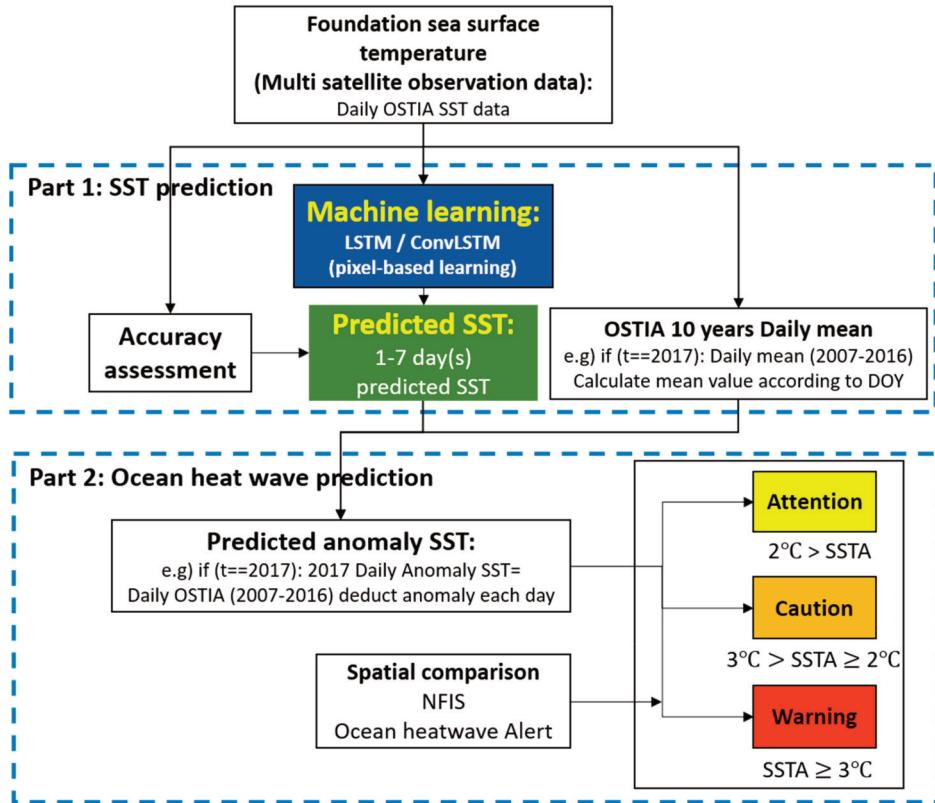


Fig. 2. The overall flowchart of this study. Part 1 is to predict sea surface temperature and Part 2 is to predict ocean heatwave.

않는데, 본 연구에서는 시·공간적 특성을 연속적으로 학습하기 위하여 Cubic interpolation을 사용하여 해당 픽셀을 보간하였다. 보간 후 각 모델의 입력자료로 사용될 때 해수면온도 데이터가 가진 특성(feature)들이 시공간적인 차이로 인한 학습 시 성능 저하 현상을 방지하기 위하여 연구기간 동안의 최대 최소값으로 0부터 1까지의 범위를 가지게 되는 정규화(normalization)를 하였다. 각 모델의 하이퍼 파라미터(hyper-parameter)는 선행연구를 참고하여 설정하였고 구체적인 수치에 대해서는 밑의 기계학습 단락에서 열거하였다.

다음으로, 고수온 탐지 파트에서 매년 남해안 연안에 대량피해를 끼치는 이상 고수온 현상 사례에 대한 탐지를 분석하였다. 고수온 속보 정의에 따르면 주의보와 경보는 각각 평년대비 2°C 와 3°C 이상의 급격한 수온 이상치가 발생한 해역 그리고 수온이 28°C 이상이 되는 경우와 3일 이상 지속되는 경우이다. 본 연구에서는 평년대비 2°C 와 3°C 이상의 이상치를 고수온 탐지에 활용

하였다. OSTIA 일일 해수면 합성장 자료를 통하여 픽셀별로 특정 날짜의 최근 10년간의 일일 수온 값의 평균을 이용하여 평년 대비 해수면 온도 이상치를 산출하였다. 예측된 해수면온도 이상치에서 주의보, 경보에 해당하는 픽셀 값을 각각 1과 2로 범주형으로 변환시켜 고수온 속보와 공간적인 분포를 비교하였다. 위의 내용은 Fig. 2와 같다.

2) 시계열 딥러닝 기법

(1) LSTM

LSTM은 시계열 자료 예측 등에 특화된 딥러닝 기법 중 하나인 Recurrent Neural Networks(RNN)의 변화된 형태의 모델로, 기존 RNN이 정보 사이의 거리가 면(장기간) 데이터에 대한 학습능력 저하를 보인다는 한계점을 보완한 모델이다(Zhong et al., 2019; Kwak et al., 2019). LSTM은 input, forget gate 등 다양한 학습기를 활용하여 RNN이 보이는 기울기 소실 현상을 완화한다(Park et al.,

2020). 그림(Fig. 3(a) LSTM)에 나타나 있듯, LSTM은 이전 cell(t-1)의 state를 받아 각각의 gate를 활용하여 cell state(h_t)를 업데이트 한 후(t), 다음 단계의 cell (t+1)로 이어지는 형태의 학습을 진행한다. 이처럼 LSTM은 cell state를 전달하는 컨베이어 벨트와 같은 구조를 취하고 있으며, 각 state를 업데이트 하기 위한 학습기로 구성되어 있다. 먼저 이전 단계에서 전달된 cell state로부터 sigmoid 함수를 활용하여 기억하고 잊어버릴 정보를 구분하는 단계를 거치게 된다. 이는 각각 input gate와 forget gate에서 전달된 h_{t-1} 과 x_t 를 활용하여 결정하며, 최종적으로는 과거 cell state (C_{t-1})를 새로운 cell state (C_t)로 업데이트가 이루어진다. 본 연구에서는 과거 14일의 해수면 온도를 이용해서 다음날의 해수면 온도를 예측하는 LSTM 모델을 구축하였으며, 지역별 차이를 고려하

여 각 픽셀별로 모델을 구축하였다. 다양한 길이의 과거 정보를 학습하는 모델을 비교한 결과, 14일이 LSTM 모델에서는 가장 최적화된 예측결과를 도출하는 것으로 나타났다. 이 과정에서 각 픽셀 별 시계열 특성의 차이로 인한 공간분포에서의 노이즈(salt-and-pepper) 효과가 나타날 수 있어, low-pass Gaussian filter를 활용하여 결과를 smoothing하는 후처리를 수행하였다. 다양한 하이퍼 파라미터를 활용한 모델간 비교를 통하여 가장 좋은 성능을 보인 adaptive moment estimation (adam) optimizer 및 0.005의 학습률(learning rate)을 설정하였다.

(2) Convolutional LSTM

ConvLSTM은 기존의 Convolutional Neural Network (CNN)과 LSTM을 결합한 Fully Connected LSTM (FC-LSTM)의 공간적인 특성을 반영하지 못한다는 단점을

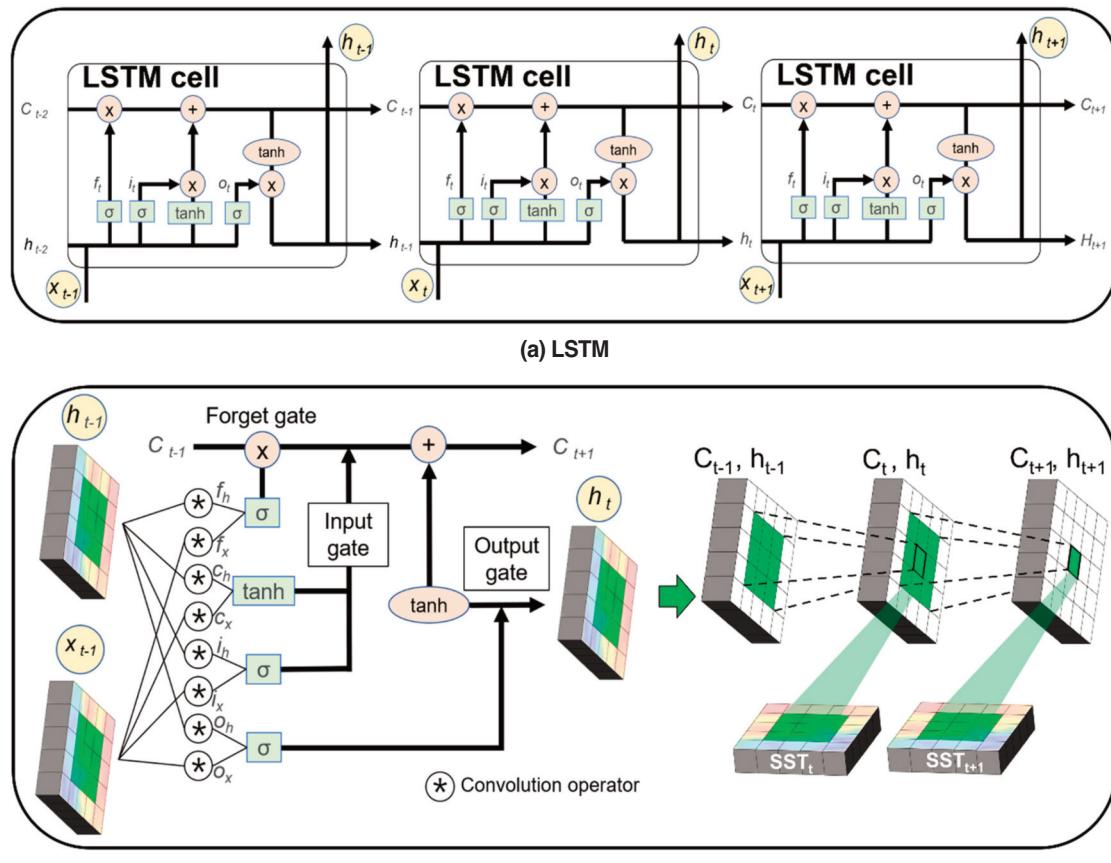


Fig. 3. The structure of (a) Long Short Term Memory (LSTM) and (b) Convolution Long Short Term Memory (ConvLSTM) models used in this research. The x , h , c , i , f , and o are input sequence, hidden state, memory cell, input gate, forget gate and output gate, respectively.

극복하기 위해서 고안되었다(Xingjian *et al.*, 2015). Conv LSTM은 기존 LSTM의 학습 방법은 동일하지만 내부 구조의 입력, 출력, 상태 레이어의 구성이 3차원의 벡터 형태로 연산되며 일반 행렬곱이 합성곱(Convolutional operator)으로 이루어져 있기에 각 ConvLSTM 셀 자체에서 시공간적인 특성을 동시에 학습할 수 있다(Fig. 3(b) ConvLSTM). 해수면 온도와 강수량 예측 시 LSTM, FC-LSTM보다 낮은 평균 오차를 보이며 우수한 성능을 보였다(Xingjian *et al.*, 2015; Kim *et al.*, 2017; Xiao *et al.*, 2019b).

이번 연구에서 사용된 필터 개수는 선행연구에서 가장 좋은 성능을 보인 20개와 커널 크기(kernel size)는 3×3 으로 선행연구에서 우수한 성능을 보여주었기에 이번 연구의 하이퍼 파라미터로 선택하였다(Xingjian *et al.*, 2015; Mu *et al.*, 2019; Xiao *et al.*, 2019b). 배치 크기는 32부터 128까지 시험을 했고 거의 유사함을 나타냈기 때문에 연산속도의 장점을 반영하기 위해서 128로 정하였다. ConvLSTM 레이어 숫자를 선택하는 것이 중요하였는데 기존의 해수면 온도 예측 선행연구에 따르면 2개에서 4개의 레이어를 사용하는 경우 좋은 성능을 보여주었다(Mu *et al.*, 2019; Xiao *et al.*, 2019). 본 연구에서는 얇은 구조에서는 커널의 크기가 전체 입력자료의 특징(feature)을 추출할 때 시간적인(temporal) 한정이 존재하므로 자료의 시공간적인 특징을 충분히 반영하여 학습을 시키기 위해 깊은 레이어의 모델을 구축함으로써 해수면 온도의 단주기, 장주기에 대한 시공간적인 변화를 충분히 학습시키기 위해 4개의 레이어를 사용하였다(Xingjian *et al.*, 2015; Mu *et al.*, 2019; Xiao *et al.*, 2019b). 마지막에 Conv3D 레이어를 추가하여 필터(filter)는 1, Kernel size는 $1 \times 1 \times 1$ 로 설정하였으며, 위의 ConvLSTM에서 나오는 출력 레이어의 차원(Dimension)을 줄여(Input shape= (28,30,40,1), Output shape= (1,30,40,1)) 28일의 과거 훈련자료를 통해 1일 예측의 결과값을 산출할 수 있도록 설정하였다. 시계열 모델을 선택하는 경우, 중요한 것은 예측 목표 날짜의 결과를 산출할 때 과거의 데이터를 기반으로 학습하기 때문에 학습에 사용되는 과거 기간이 중요하므로 본 연구에서는 예측 날짜의 4배인 기간인 28일을 학습시켜 변화하는 주기성을 반영하였다(Zhang *et al.*, 2017; Xiao *et al.*, 2019b). 학습을 안정적으로 하기 위해 옵티마이저(optimizer)를 설정할 때 선행연구 및 본 연구에서 가장 우수한 성능을 보인 adam을 선

택하였다(Xiao *et al.*, 2019b). 두 모델 모두 예측 기간에 따른 학습 시 예측된 자료를 다시 입력자료로 활용하여 예측 결과를 산출하였다.

3) 정확도 평가

두 가지 딥러닝 기반 해수면 온도의 시계열 자료에 대한 일별 예측 모델의 성능을 비교·분석하기 위하여 본 연구는 다음과 같은 두 가지 지표를 활용하였다. 먼저, 평균 오차(Mean Difference: MD, 식 1)의 경우, 관측 값에서 예측 값을 뺀 오차에 대한 평균값으로, 과추정(overestimation), 혹은 저추정(underestimation)과 같은 공간적인 오차의 패턴을 분석할 때 용이하다. 먼저, RMSE (Root Mean Square Error; 식 2)의 경우, 관측 값과 예측 값 사이 오차의 절댓값을 활용한 지표로, Mean Difference (MD)와 비교하여 과추정 및 저추정의 패턴을 파악하기에는 어렵지만, 공간적인 오차의 절대적인 분포를 비교하는데 용이하다(Kim *et al.*, 2019).

$$MD = \frac{1}{n} \sum_{i=1}^n (y_i - x_i) \quad (1)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - x_i)^2}{n}} \quad (2)$$

위 식의 n , y_i 와 x_i 는 각각 자료의 개수, OSTIA 레퍼런스(Reference), 예측 값이다.

4. 연구결과 및 토의

1) 예측 오차 변화 분석

전체 테스트 기간(2017-2019)과 상대적으로 예측 오차가 크게 나타나는 여름 계절(6, 7, 8월)에 대한 예측오차를 RMSE를 활용하여 비교·분석하였다(Fig. 4). 전체 기간에 대한 평균 예측 RMSE의 경우(1~7days lead time), LSTM $\approx 0.69^{\circ}\text{C}$, ConvLSTM $\approx 0.56^{\circ}\text{C}$ 로 ConvLSTM \approx LSTM에 비하여 상대적으로 높은 예측력을 보여주었다. Fig. 4에서 전체적인 오차는 선행연구(Xiao *et al.*, 2019b)와 비교하여 본 연구의 모델의 결과가 상대적으로 우수하며 특히 ConvLSTM의 결과에서 7일 예측의 결과에서 약 0.71°C 로 선행연구에서 나타난 약 0.85°C 의 RMSE 오차와 비교하여 상대적으로 높은 예측 성능을 보였는데 두 연구의 활용된 위성 자료의 특성, 연산에 활용된

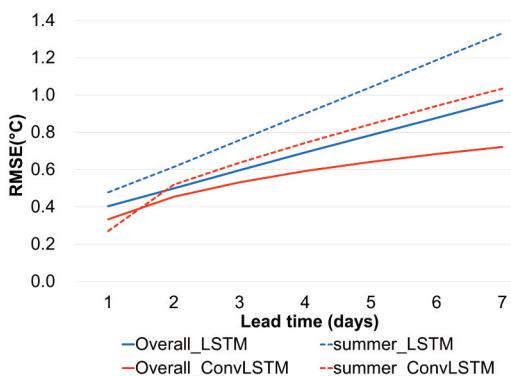


Fig. 4. Overall and summer RMSEs with different lead time (1-7 days). The red lines are RMSEs of ConvLSTM and the blue lines are RMSEs of LSTM. Dash lines indicate summer RMSEs.

픽셀 량(Xiao *et al.*(2019b): 22×16 , 본 연구: 30×40) 그리고 모델의 깊이 차이(선행 연구: 2 ConvLSTM layer, 본 연구: 4 ConvLSTM layer)에 따른 정확도 차이가 발생했을 것으로 보인다. 모델의 깊이는 시계열 자료를 학습한 딥러닝 모델의 학습 깊이와 연관이 있는 것으로 보이며, 시공간적 패턴을 나타내는 자료의 특징(feature)을 충분히 학습한 결과로 판단된다. 여름철에 대한 평균 예측 RMSE 또한 LSTM이 약 0.90°C , ConvLSTM이 약 0.71°C 로 ConvLSTM의 예측 정확도가 더 높음을 보여주었다. 예측 오차의 경우, 선형성을 보이는 양상은 이는 연구지역에 대한 특성과 본 연구에서 설정한 두 모델의 하이퍼 파라미터에 의해 나타난 영향이 학습 결과에 반영되므로 오차의 증가와 다른 패턴을 보인다. 예측 기간이 길어짐에 따라 LSTM모델의 RMSE가 ConvLSTM 모델보다 더욱 빠르게 증가하는 것으로 나타났으며, 일 변화가 상대적으로 큰 여름철의 예측 오차가 더욱 빠르게 증가하는 것으로 나타났다. LSTM과 ConvLSTM의 오차 증가폭을 비교했을 때 LSTM이 더 큰 것으로 나타났다. 이는 합성곱, 즉 주변 픽셀의 영향을 반영하는 경우 모델의 성능이 대체적으로 더 뛰어나기 때문인 것으로 판단된다(Xiao *et al.*, 2019b).

2) 일일 해수면 온도 예측 결과 정확도 분석

LSTM과 ConvLSTM을 활용한 연구지역 내 해수면 온도의 일일 예측 값(daily prediction)에 대한 오차 및 4계절(봄, 여름, 가을, 겨울)에 대한 각 계절별 예측 정확도를 비교하였다(Fig. 5). 전 계절 뿐만 아니라, 각 계절에

대한 예측 RMSE 기준으로 ConvLSTM(전체: 0.33°C , 봄(3, 4, 5월): 0.34°C , 여름(6, 7, 8월): 0.27°C , 가을(9, 10, 11월): 0.32°C , 겨울(12, 1, 2월): 0.36°C)이 LSTM기반의 예측 모델(전체: 0.40°C , 봄(3, 4, 5월): 0.40°C , 여름(6, 7, 8월): 0.48°C , 가을(9, 10, 11월): 0.39°C , 겨울(12, 1, 2월): 0.34°C)보다 전반적으로 높은 예측 정확도를 보였다. 고수온 등의 이상 해수면 온도 현상이 발생하는 여름의 경우, ConvLSTM 모델의 1일 예측 정확도는 다른 계절보다 상대적으로 낮은 RMSE를 보였지만 LSTM 모델은 다른 계절과 비교하여 가장 높은 RMSE를 보였다. Fig. 5의 공간적 분포의 경우, 전반적으로 수심이 얕아지는 연안에 가까운 지역일수록 예측 정확도가 상대적으로 낮은 것으로 나타났다. 우리나라의 남해안을 따라 흐르는 대마 난류의 흐름과 세기에 따른 예측 지역적인 변동으로 인한 공간적 분포 오차가 발생하는 것으로 보이며(NA *et al.*, 1990; CHoo and Kim, 1998), 이로 인한 일일 예측 오차가 함께 발생한 것으로 보인다. 본 연구에서 활용한 OSTIA 자료의 특성으로 인한 오류 또한 발생할 수 있는데, 위성자료와 현장 관측 자료를 동화하여 일일 산출물을 생산하는 OSTIA 해수면 온도 합성 자료의 특성 상본 연구지역은 연안지역과 가까워 대부분 마이크로파 기반의 위성 자료가 활용되지 않고 열적외 위성 자료와 현장 관측 자료가 동화에 활용된다(Donlon *et al.* 2014). 온도 합성 자료에 동화되는 자료는 구름, 날씨 등의 이유로 일일 OSTIA 자료에 반영이 되지 않을 수 있으며, 특히 특정 해의 계절적인 해수면 온도 자료 동화량과 같은 위성자료 자체의 요인과 외부에서 유입되는 난류 등의 환경적인 요인을 고려하는데 한계점이 있는 것으로 판단된다.

결과가 각 계절 별 해수면 온도의 공간 분포 예측 결과를 분석하기 위하여 본 연구에서는 2019년 기준 봄(2019. 01. 01), 여름(2019. 04. 01), 가을(2019. 07. 01), 겨울(2019. 10. 01)에 대한 일일 수온예측 결과에 대한 공간 분포를 비교·분석하였다(Fig. 6). 봄, 여름, 겨울의 경우, 평균적으로 연안에서 외해로 넘어갈수록 온도가 증가하는 패턴을 보인다. 앞서 두 모델의 계절별 1일 예측 모델의 RMSE 비교 시 ConvLSTM 모델의 경우 LSTM 모델보다 겨울을 제외한 모든 계절에서 상대적으로 높은 정확도(낮은 RMSE)를 보였으며 일일 예측의 공간 분포 계절적 RMSE 결과와 비교 시 겨울을 제외한 모든 계절

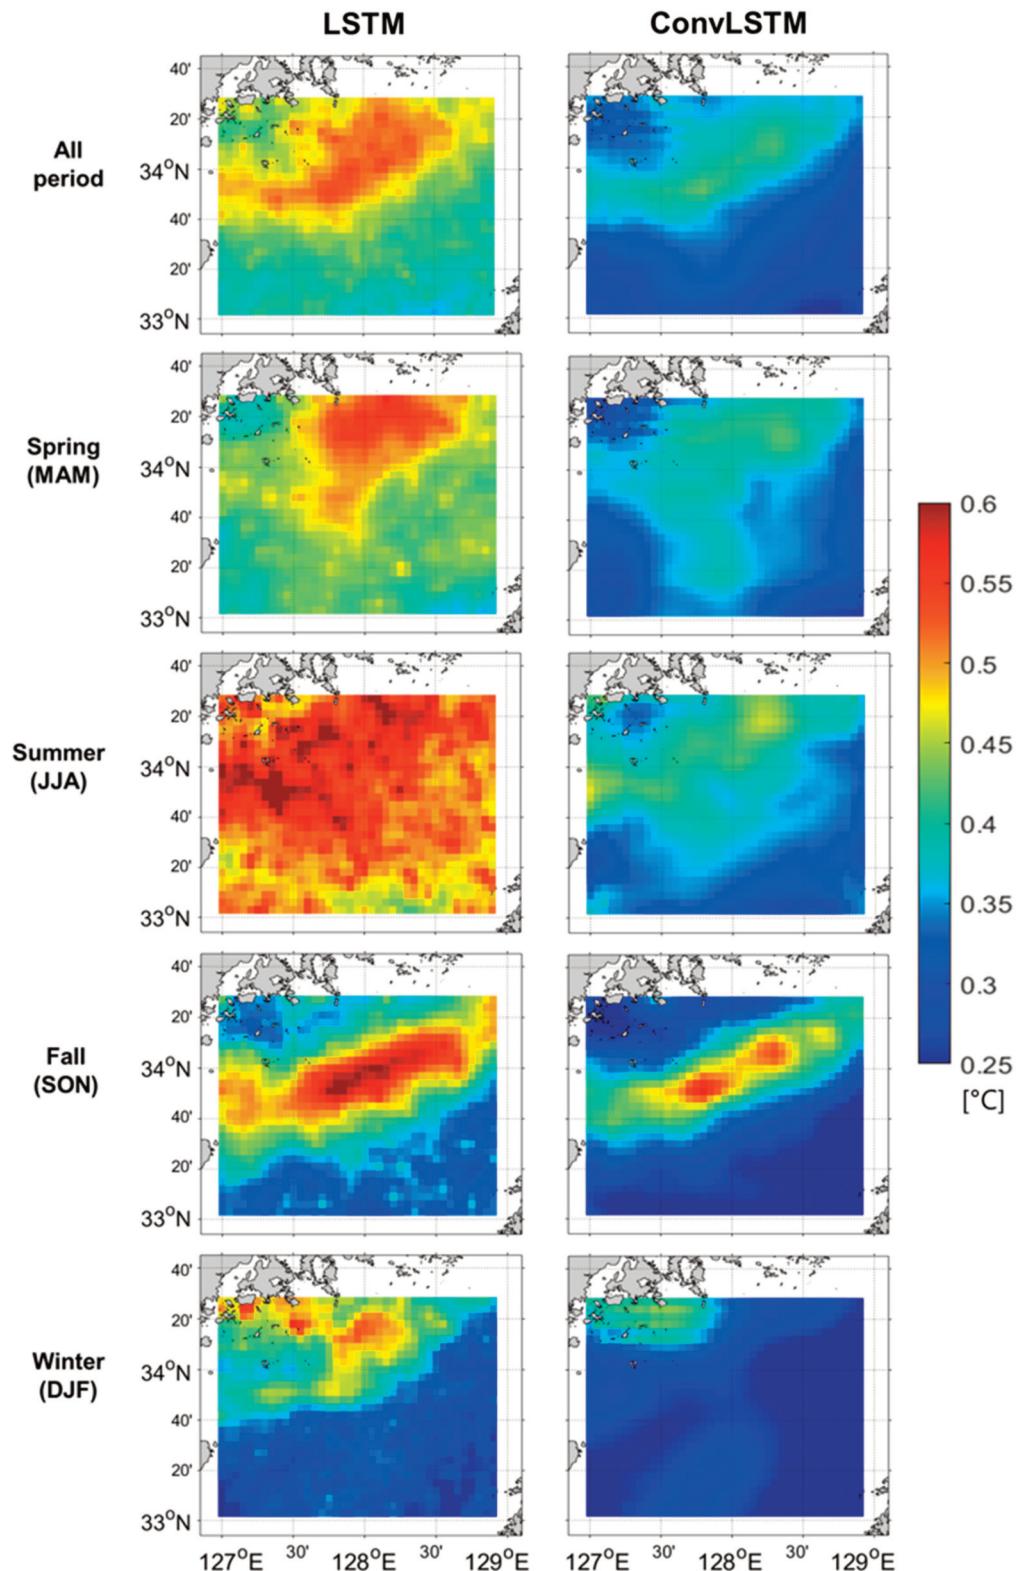


Fig. 5. Spatial distribution of RMSEs and their seasonal patterns using the 1-day prediction model.

에서 유사함을 보였다. ConvLSTM 모델이 LSTM 기반의 예측모델보다 상대적으로 높은 예측 정확도를 보이는 것으로 나타났으며, 특히 각 픽셀별로 훈련한 LSTM 예측모델의 경우, 공간분포에 대한 상대적으로 높은 노이즈(salt-and-pepper) 현상을 보이는 것으로 나타났다.

픽셀별로 모델링 하는 LSTM의 공간적 노이즈 등을 해결하기 위해서 주변 픽셀에 대한 공간적인 특성을 반영 할 수 있는 공간적 기법(CNN)을 적용한 기법(FC-LSTM, ConvLSTM)을 통해 해결할 수 있을 것으로 보인다. 또한, Fig. 6의 결과에서 Fig. 5의 결과와 마찬가지로, 2019년

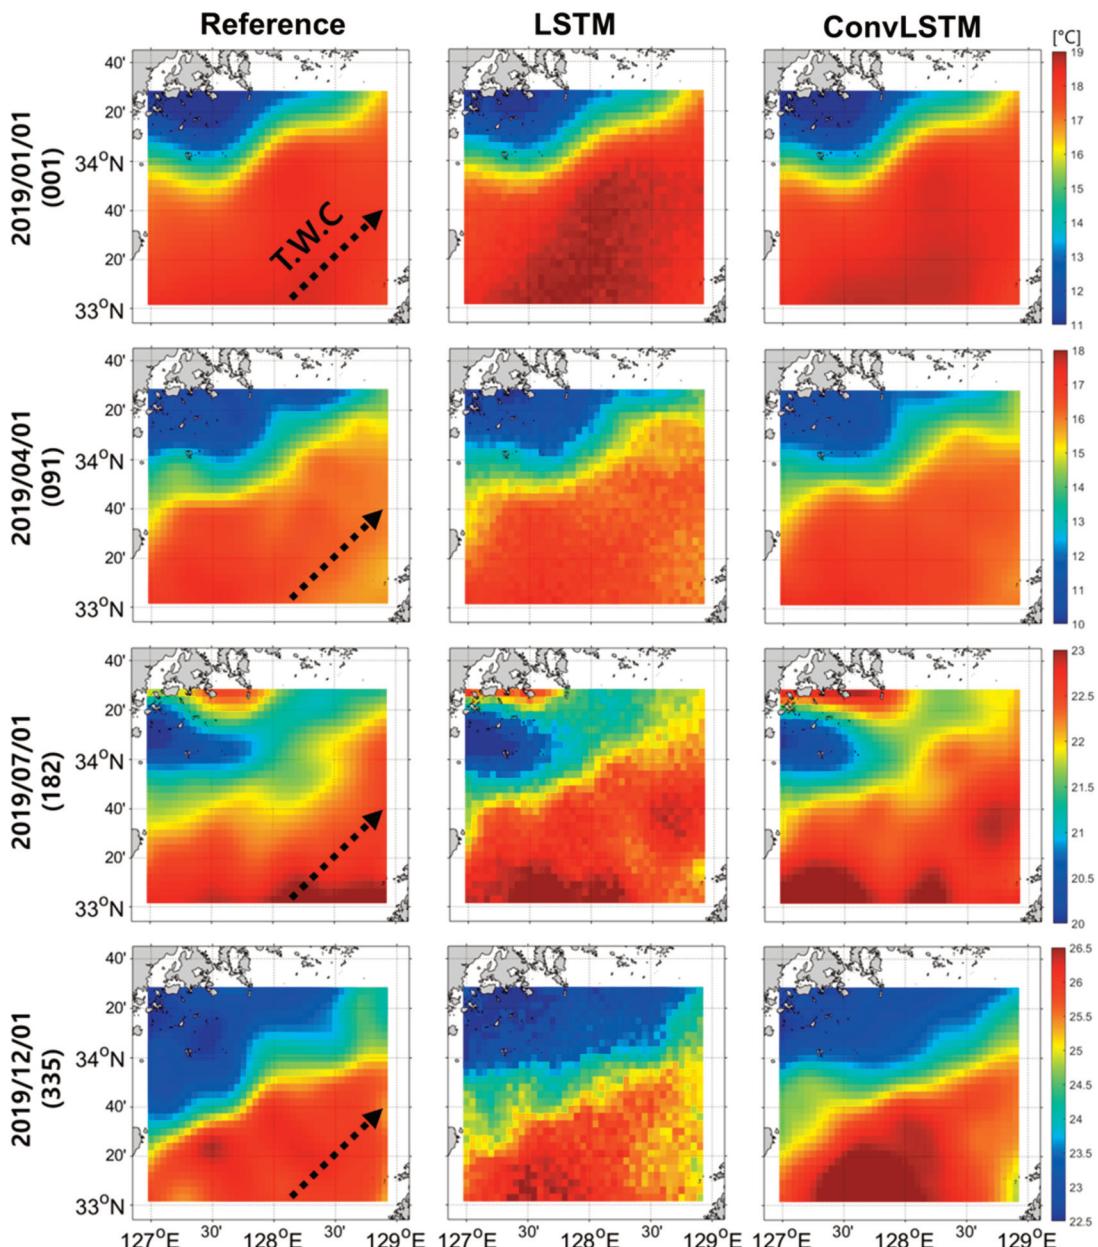


Fig. 6. Spatial distribution of sea surface temperature predicted using the 1-day prediction LSTM and ConvLSTM models for four days in 2019. The number in parentheses is day of year in 2019. The scale bars change with date and place on left side of each row. The black dashed lines on the reference images indicate the streamline of Tsushima Warm Current (T.W.C.).

7월 1일과 12월 1일에 대마난류의 흐름에 의한 과대 또는 과소추정의 결과가 관측된다(그림의 우측 중간 부분의 T.W.C.).

3) 예측 기간별 공간적 오차 분석

LSTM, ConvLSTM 모델을 이용한 중단기 예측의 검증 자료의 공간적인 오차를 분석하였다(Fig. 7). 두 모델

모두 예측 일수가 증가함에 따라 예측 오차가 비례하여 증가하는 것으로 나타났다. 특히 MD의 경우, LSTM이 예측 기간이 증가함에 따라 공간적으로 불연속적인 오차 패턴이 나타나는 것과 비교하여, ConvLSTM 모델은 연속적인 양의 오차(positive error)만 나타나는 것으로 나타났다. 또한, LSTM과 ConvLSTM 모델의 ME에 대한 공간적 분포를 비교하였을 때, 각 픽셀별로 훈련된

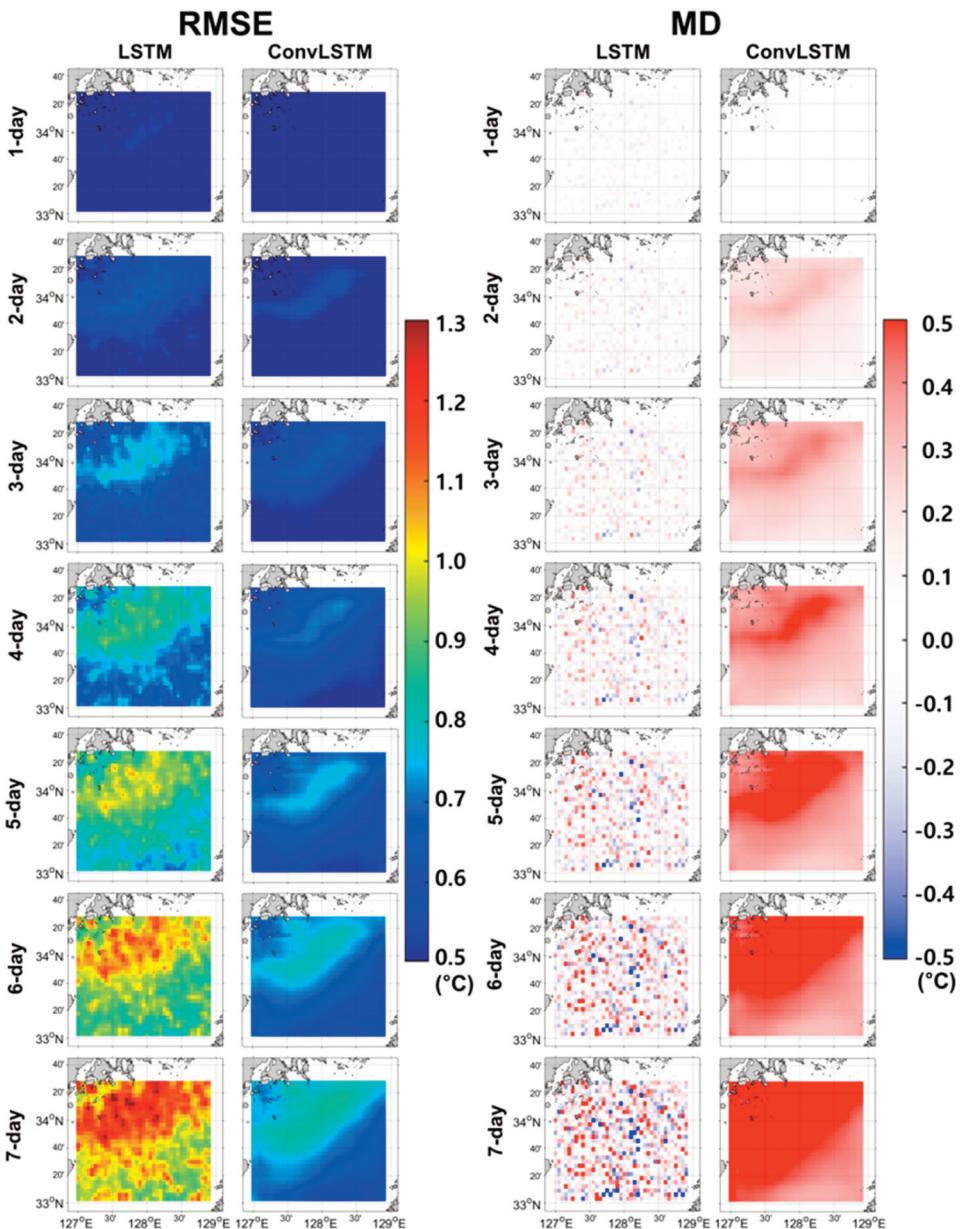


Fig. 7. Spatial distribution of root mean square error (RMSE) and mean difference (MD) based on the LSTM and ConvLSTM models by lead time.

LSTM 모델이 상대적으로 높은 공간적 노이즈를 보이는 것으로 나타났으며, 과소추정과 과대 추정하는 패턴이 골고루 나타났다. RMSE를 활용한 두 모델의 해수면 온도 예측 단계별 오차의 공간분포 또한 LSTM 기반 예측 모델이 ConvLSTM 모델에 비하여 상대적으로 낮은 예측 정확도를 보였다. 두 모델 모두, 예측기간 4일을 기준으로 급격히 증가하는 것으로 나타났으며, 연안지역이 원해지역에 비하여 상대적으로 더 높은 RMSE를 보이는 것으로 나타났다. 이는 앞서 다루었던 대마난류에 의하여 예측 오차가 커진 것으로 분석된다(CHoo and

Kim, 1998). 합성곱 연산(convolutional operator)이 필터에 숫자에 따른 연산이 증가됨에 따라 예측 자료의 값(value)이 예측을 거듭할수록 Smoothing되는 경향이 ConvLSTM모델에서 보이며 두 예측 모델 모두 거문도 남동쪽-제주도 북동쪽 해역(그림의 중간 부분)부터 RMSE와 MD가 서서히 증가되며 주변 영역으로 확대되는 현상을 보였다(Fig. 7).

4) 고수온 영역 탐지 활용 결과

국립수산과학원에서 제공하는 고수온 속보와 두 모

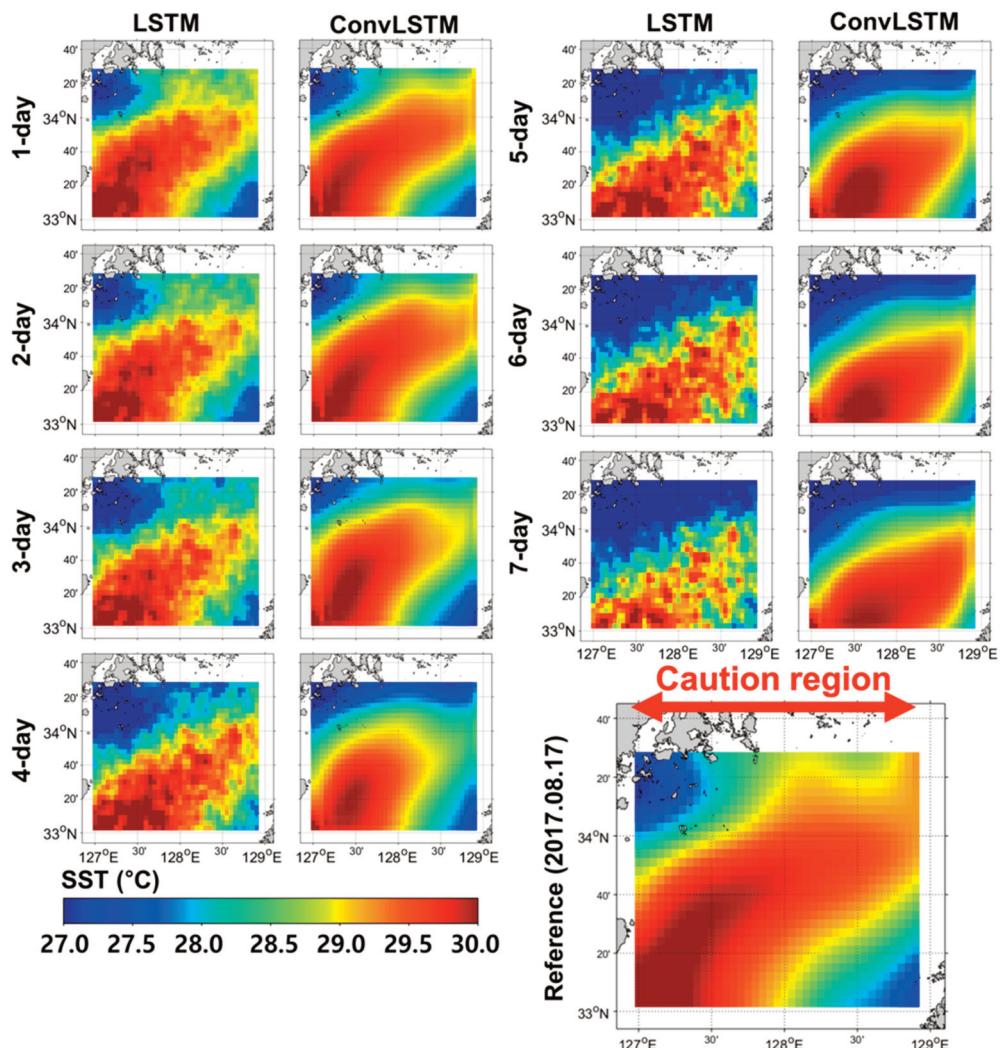


Fig. 8. Sea surface temperature prediction with multi lead times using LSTM and ConvLSTM for the ocean heat wave case on 2017/08/17. The number of days is the red arrow in the reference image indicates that all area of southern sea is in ocean heat wave 'caution' category based on NIFS' coastal monitoring database.

델에서 예측한 해수면의 비교 및 분석을 수행하였다. 국립수산과학원에서 제공된 고수온 속보는 연안의 정점 자료로부터 산출되었기에 연안의 국지적으로 고수온이 발생한 경우와 본 연구의 예측 모델과 비교하는 경우에는 공간적인 분포의 동일성을 보일 수 없는 한계를 가진다. 인공위성 산출 해수면 온도는 표층 뜰개 부이와의 측정 수심이 다르기 때문에 오차가 존재하며 연안과의 거리에 따른 정확도에 차이가 있다(Park *et al.*, 2008). 본 연구에서 활용된 OSTIA는 파운데이션 해수면 온도(foundation SST)를 산출하여 주간 효과(Diurnal warming)을 제거하였기 때문에 표층 해수면 온도와 차이가 생길

수 있으며 직접 비교하기에 한계가 있다(Donlon *et al.*, 2012; Woo *et al.*, 2020). 고수온이 발생한 2017년 8월 17일을 대상으로 두 모델의 예측 결과를 비교해 본 결과 ConvLSTM이 LSTM에 비해 1-7일 예측 모두 레퍼런스 해수면 온도와 유사한 공간적 분포를 보여준다(Fig. 8). Fig. 9과 Fig. 10은 각각 LSTM, ConvLSTM의 이상치(anomaly)와 고수온 카테고리에 대한 시공간적인 분포를 나타낸다. LSTM의 결과에서 이상치는 2일 이상 예측 시 급격한 탐지 성능 저하가 생기며 대부분 해역에 대한 주의보(cautio)를 예측하지 못하는 것으로 나타났다. 또한, 예측 기간이 증가함에 따라 예측 이상치 면

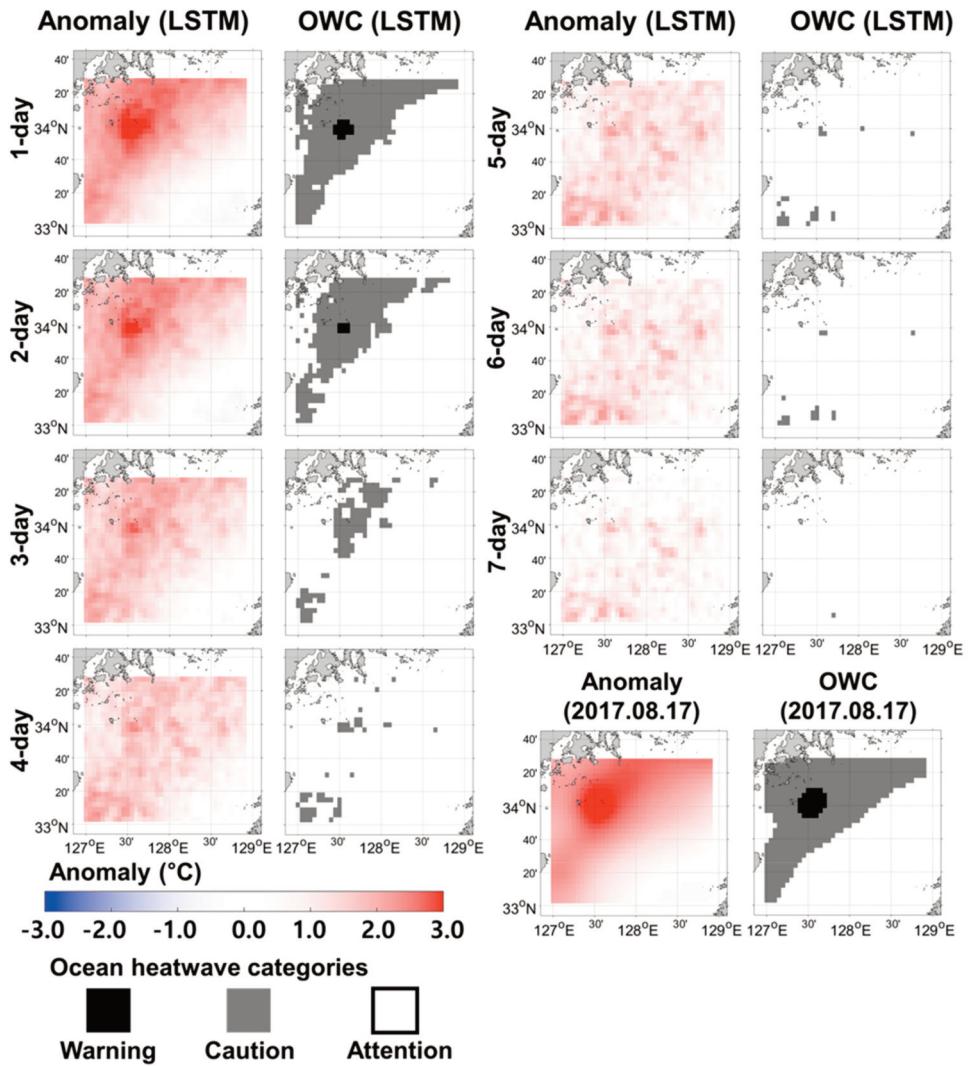


Fig. 9. Spatial distribution of the SST anomaly and ocean heatwave category (OWC) for LSTM. Ocean heatwave categories are warning, caution and attention.

적이 급격히 감소하며 예측 해수면 온도 값의 과소 추정으로 인해 전체적으로 고수온 탐지를 과소 모의하는 경향을 보였다. ConvLSTM의 결과에서는 시공간적인 분포에서 고수온 탐지 지역의 범위가 LSTM보다 상대적으로 서서히 감소되며, 예측 기간이 5일 이상이 되는 시점부터 경보 예측의 오차가 커지는 경향을 보인다. 위의 예측 기간별 공간적 오차와 RMSE의 결과와 동일하게 LSTM의 경우 각 픽셀마다 모델링을 하기 때문에 LSTM 고수온 카테고리 결과에서 제주도 남동쪽 해역(그림의 좌하단)의 픽셀은 5일까지 이상치를 적절히 모의하는 반면 이외의 부분에서는 과소 추정하였다(Fig. 9). 반면

ConvLSTM 모델 결과에 따르면 2, 3일전 제주도 동쪽 해역(그림의 중간 부분)에서 과대 추정으로 인해 이상치가 증가됨에 따라 경보 범위가 확대되었으며 주의보 픽셀들은 과소 추정하는 경향이 나타나며 범위가 축소되었다(Fig. 10). 과대 추정을 하는 경향을 가진 픽셀에 대해서는 주의보, 경보에 대한 탐지를 할 수 있지만 과소 추정하는 경우 탐지할 수 없는 한계를 가지게 된다. 두 예측 모델 모두에서 예측 기간이 길어짐에 따라 주의보와 경보의 면적 추정 시 과소 모의하는 경향이 뚜렷하므로 예측 기간의 연장에 따라 고수온 탐지 영역의 축소 현상이 일어났다.

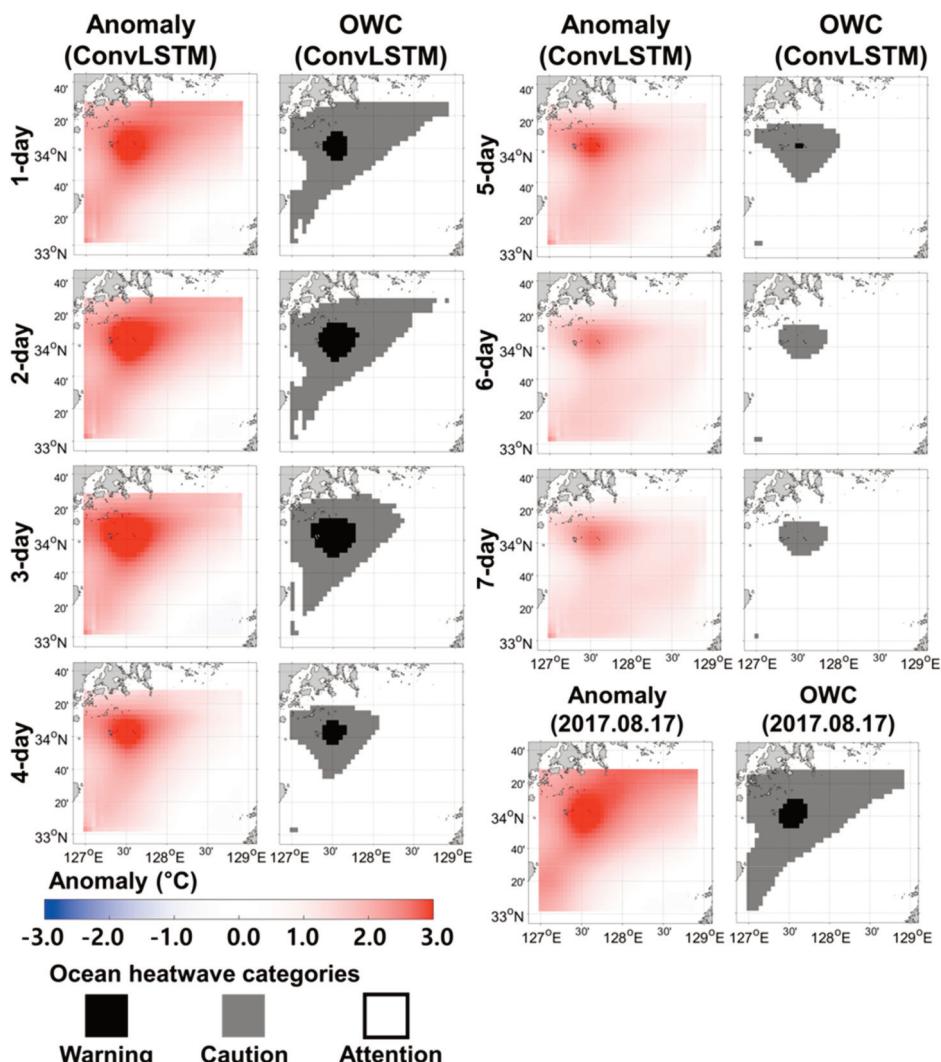


Fig. 10. Spatial distribution of the SST anomaly and ocean heatwave category (OWC) for ConvLSTM. Ocean heatwave categories are warning, caution, and attention.

5. 결론

본 연구에서는 LSTM, ConvLSTM 딥러닝 모델을 활용하여 우리나라 남해지역의 중단기 해수면 온도 예측, 고수온 해역 탐지에 대해 분석하였다. LSTM의 정확도는 선행연구와 비슷한 수준을 보였고 특히 ConvLSTM 모델은 기존 해수면 온도 예측 연구 결과보다 상대적으로 우수한 성능을 보였다(LSTM 모델의 RMSE: 0.40°C, ConvLSTM 모델의 RMSE: 0.33°C). 여름철 이상 고수온이 발생한 경우, 본 연구의 중단기 예측모델에서 LSTM은 약 2일전, ConvLSTM은 5일전 탐지가 가능하였다. 중단기 해수면 온도를 예측함에 있어 시계열 자료 기반의 모델 특성상, 예측 기간이 길어질수록 과소 및 과대 추정을 하는 경향이 커지게 되는데, 이는 향후 편차 보정을 위한 양상을 기법(Adaboost, Bias corrected random forest 등)을 활용하여 해수면 온도 예측 성능을 개선한다면 장기간(7일 이상) 예측 시 오차의 증가 폭을 줄여 고수온 탐지 영역의 축소 현상도 다소 줄일 수 있을 것으로 보인다(*Cho et al., 2020; Xiao et al., 2019a*).

사사

이 연구는 해양수산부(Ministry of Ocean and Fisheries)의 다종위성 기반 해양 현안대응 실용화 기술 개발(20180456)과 과학기술정보통신부 및 정보통신기획평가원의 대학ICT연구센터지원사업(IITP-2020-2018-01424)의 지원으로 수행되었습니다.

References

- Chin, T. M., J. Vazquez-Cuervo, and E. M. Armstrong, 2017. A multi-scale high-resolution analysis of global sea surface temperature, *Remote sensing of Environment*, 200: 154-169.
- Cho, D., C. Yoo, J. Im, and D. H. Cha, 2020. Comparative Assessment of Various Machine Learning-Based Bias Correction Methods for Numerical Weather Prediction Model Forecasts of Extreme Air

- Temperatures in Urban Areas, *Earth and Space Science*, 7(4): 1-18.
- CHOO, H.-S. and D.-S. KIM, 1998. The effect of variations in the Tsushima warm currents on the egg and larval transport of anchovy in the southern sea of Korea, *Korean Journal of Fisheries and Aquatic Sciences*, 31(2): 226-244. (in Korean with English abstract).
- Donlon, C. J., M. Martin, J. Stark, J. Roberts-Jones, E. Fiedler, and W. Wimmer, 2012. The operational sea surface temperature and sea ice analysis (OSTIA) system, *Remote Sensing of Environment*, 116: 140-158.
- Kim, S., S. Hong, M. Joh, and S.-K. Song, 2017. Deeprain: Convlstm network for precipitation prediction using multichannel radar data, 1711 (202316): 1-4.
- Kim, T.-H. and C.-S. Yang, 2019. Preliminary Study on Detection of Marine Heat Waves using Satellite-based Sea Surface Temperature Anomaly in 2017-2018, *Journal of the Korean Society of Marine Environment & Safety*, 25(6): 678-686. (in Korean with English abstract).
- Kim, Y. J., H.-C. Kim, D. Han, S. Lee, and J. Im, 2020. Prediction of monthly Arctic sea ice concentrations using satellite and reanalysis data based on convolutional neural networks, *The Cryosphere*, 14: 1083-1104.
- Korea Institute of Science and Technology (KIOST), 2013. *Report on Development of Korea Operational Oceanographic System (KOOS)*, Korea Institute of Science and Technology, Busan, KR (in Korean).
- Korea Institute of Science and Technology (KIOST), 2018. Press, Korea Institute of Ocean Science and Technology, http://www.kiost.ac.kr/synap/skin/doc.html?fn=BBS_201808290917391950.hwp&rs=/viewerresult/BBSMSTR_000000000075/, Accessed on Aug. 29, 2018 (in Korean).
- Korea Meteorological Administration (KMA), 2019. *Abnormal climate report in 2018*, Korea

- Meteorological Administration, Seoul, KR (in Korean).
- Kwak, G.-H., M.-G. Park, C.-W. Park, K.-D. Lee, S.-I. Na, H.-Y. Ahn, and N.-W. Park, 2019. Combining 2D CNN and bidirectional LSTM to consider spatio-temporal features in crop classification, *Korean Journal of Remote Sensing*, 35(5-1): 681-692 (in Korean with English abstract).
- Lee, S.-H., Y.-G. Kim, J.-T. Yoo, and S.-H. Song, 2018. Characteristics of egg and larval distributions and catch changes of anchovy in relation to abnormally high sea temperature in the South Sea of Korea, *Journal of the Korean Society of Fisheries and Ocean Technology*, 54(3): 262-270 (in Korean with English abstract).
- Lins, I. D., M. Araujo, M. das Chagas Moura, M. A. Silva, and E. L. Drogue, 2013. Prediction of sea surface temperature in the tropical Atlantic by support vector machines, *Computational Statistics & Data Analysis*, 61: 187-198.
- Martin, M., E. Fiedler, J. R. Jones, E. Blockley, A. McLaren, and S. Good, 2019. PRODUCT USER MANUAL For OSTIA Near Real Time Level 4 SST products over the global ocean: SST-GLO-SST-L4-NRT-OBSERVATIONS-010-001, Copernicus.
- Moon, J.-E. and C.-S. Yang, 2009. Analysis of abnormal sea surface temperature in the coastal waters of the Yellow Sea using satellite data for the winter season of 2004, *Korean Journal of Remote Sensing*, 25(1): 1-10 (in Korean with English abstract).
- Mu, B., C. Peng, S. Yuan and L. Chen, 2019. ENSO Forecasting over Multiple Time Horizons Using ConvLSTM Network and Rolling Mechanism, *Proc. of 2019 International Joint Conference on Neural Networks (IJCNN)*, Budapest, Hungary, Jul. 14-19, pp. 1-8.
- NA, J.-Y., S.-K. HAN, and K.-D. CHO, 1990. A study on sea water and ocean current in the sea adjacent to Korea peninsula-expansion of coastal waters and its effect on temperature variations in the South Sea of Korea, *Korean Journal of Fisheries and Aquatic Sciences*, 23(4): 267-279 (in Korean with English abstract).
- Nan, F., H. Xue, and F. Yu, 2015. Kuroshio intrusion into the South China Sea: A review, *Progress in Oceanography*, 137: 314-333.
- Park, K., F. Sakaida, and H. Kawamura, 2008. Oceanic skin-bulk temperature difference through the comparison of satellite-observed sea surface temperature and in-situ measurements, *Korean Journal of Remote Sensing*, 24(4): 273-287 (in Korean with English abstract).
- Park, H.-W., S.-H. Lee, E.-J. Lee, Y.-S. Cho, Y.-S. Park, J.-H. Lee, and D.-H. Yoo, 2020. Short-term forecasting for sea surface temperature based on tidal observatory observations, *Journal of the Korean Data And Information Science Society*, 31(2): 255-271 (in Korean with English abstract).
- Reynolds, R. W., T. M. Smith, C. Liu, D. B. Chelton, K. S. Casey, and M. G. Schlax, 2007. Daily high-resolution-blended analyses for sea surface temperature, *Journal of Climate*, 20(22): 5473-5496.
- Seong, K.-T., J.-D. Hwang, I.-S. Han, W.-J. Go, Y.-S. Suh, and J.-Y. Lee, 2010. Characteristic for long-term trends of temperature in the Korean waters, *Journal of the Korean Society of Marine Environment & Safety*, 16(4): 353-360 (in Korean with English abstract).
- Woo, H.-J. and K. Park, 2020. Inter-Comparisons of Daily Sea Surface Temperatures and In-Situ Temperatures in the Coastal Regions, *Remote Sensing*, 12(10): 1592.
- Xue, Y. and Leetmaa, A, 2000. Forecasts of tropical Pacific SST and sea level using a Markov model, *Geophysical Research Letters*, 27(17): 2701-2704.
- Xiao, C., N. Chen, C. Hu, K. Wang, J. Gong, and Z. Chen, 2019a. Short and mid-term sea surface temperature prediction using time-series satellite

- data and LSTM-AdaBoost combination approach, *Remote Sensing of Environment*, 233: 111358.
- Xiao, C., N. Chen, C. Hu, K. Wang, Z. Xu, Y. Cai, L. Xu, Z. Chen, and J. Gong, 2019b, A spatiotemporal deep learning model for sea surface temperature field prediction using time-series satellite data, *Environmental Modelling & Software*, 120: 104502.
- Xingjian, S., Z. Chen, H. Wang, D.-Y. Yeung, W.-K. Wong, and W.-C. Woo, 2015. Convolutional LSTM network: A machine learning approach for precipitation nowcasting, *Advances in Neural Information Processing Systems*, 2015: 802-810.
- Yang, Y., J. Dong, X. Sun, E. Lima, Q. Mu, and X. Wang, 2017. A CFCC-LSTM model for sea surface temperature prediction, *IEEE Geoscience and Remote Sensing Letters*, 15(2): 207-211.
- Zhang, Q., H. Wang, J. Dong, G. Zhong, and X. Sun, 2017, Prediction of sea surface temperature using long short-term memory, *IEEE Geoscience and Remote Sensing Letters*, 14(10): 1745-1749.
- Zhong, L., L. Hu. and H. Zhou, 2019. Deep learning based multi-temporal crop classification, *Remote Sensing of Environment*, 221: 430-443.